

# Fundamentos del Filtrado Espacial

Procesamiento Digital de Imágenes

Nombre del Presentador  
*Institución/Departamento*

21 de mayo de 2025

# Contenido

- 1 Introducción al Filtrado Espacial
- 2 Mecánica del Filtrado Lineal
- 3 Correlación y Convolución
- 4 Kernels y Filtrado Secuencial
- 5 Resumen y Conclusiones

## Filtrado Espacial

El **filtrado espacial** se refiere a la modificación del valor de cada píxel de una imagen en función de los valores del propio píxel y sus vecinos. Es una técnica fundamental en el procesamiento de imágenes, utilizada principalmente para **realce (enhancement)** y restauración.

El nombre "filtro" se toma del procesamiento en el **dominio de la frecuencia** (Capítulo 4 del material original), donde "filtrar" implica:

- Pasar, modificar o rechazar componentes de frecuencia específicos de una imagen.
- Ejemplo: Un *filtro paso-bajas* atenúa las altas frecuencias, resultando en un suavizado o difuminado (blurring) de la imagen.
- Efectos similares de suavizado se pueden lograr directamente en el dominio espacial.

# Tipos de Filtros Espaciales

El filtrado espacial modifica una imagen reemplazando el valor de cada píxel por una función de los valores del píxel y sus vecinos.

## Filtro Lineal Espacial

La operación realizada sobre los píxeles de la imagen es **lineal**. Nos centraremos inicialmente en estos filtros.

## Filtro No Lineal Espacial

La operación realizada sobre los píxeles es **no lineal**. Se introducirán algunos filtros no lineales básicos más adelante (referencia a Sección 5.3 del material original).

# El Kernel del Filtro

Un filtro espacial lineal realiza una operación de **suma de productos** entre una sub-área de la imagen  $f$  y una matriz llamada **kernel de filtro**  $w$ .

- El **kernel** (o núcleo) es un arreglo (generalmente 2D) de coeficientes.
- Sus **coeficientes** determinan la naturaleza y el comportamiento del filtro (e.g., suavizado, realce de bordes).
- El **tamaño del kernel** define la vecindad de píxeles considerada para cada operación.
- **Otros términos comunes** para el kernel:
  - Máscara (mask)
  - Plantilla (template)
  - Ventana (window)

# Operación con un Kernel $3 \times 3$


## Respuesta del Filtro $g(x, y)$

En cualquier punto  $(x, y)$  de la imagen, la respuesta  $g(x, y)$  del filtro es la suma de productos de los coeficientes del kernel y los píxeles de la imagen cubiertos por el kernel:

$$\begin{aligned} g(x, y) = & w(-1, -1)f(x - 1, y - 1) + w(-1, 0)f(x - 1, y) + w(-1, 1)f(x - 1, y + 1) \\ & + w(0, -1)f(x, y - 1) + w(0, 0)f(x, y) + w(0, 1)f(x, y + 1) \\ & + w(1, -1)f(x + 1, y - 1) + w(1, 0)f(x + 1, y) + w(1, 1)f(x + 1, y + 1) \end{aligned} \quad (3-30)$$

- A medida que las coordenadas  $x$  e  $y$  varían, el centro del kernel se mueve de píxel a píxel, generando la imagen filtrada  $g$ .
- El coeficiente central del kernel,  $w(0, 0)$ , se alinea con el píxel en la ubicación  $(x, y)$  de la imagen original  $f$ .

# Ilustración del Filtrado Lineal (Fig. 3.28)



**Figura:** Mecánica del filtrado espacial lineal (conceptual, Fig. 3.28). El kernel se desliza sobre la imagen, calculando la suma de productos en  $(x, y)$ .

## Orígenes

El origen de la imagen suele ser la esquina superior izquierda. Para simplificar las expresiones, el origen del kernel se define en su centro, especialmente para kernels simétricos.

# Expresión General y Tamaño del Kernel

Para un kernel de tamaño  $m \times n$ , se asume que  $m = 2a + 1$  y  $n = 2b + 1$ , donde  $a, b$  son enteros no negativos. Esto implica que nos centramos en kernels de **tamaño impar** en ambas direcciones. El filtrado espacial lineal de una imagen de tamaño  $M \times N$  con un kernel de  $m \times n$  está dado por:

$$g(x, y) = \sum_{s=-a}^a \sum_{t=-b}^b w(s, t) f(x + s, y + t) \quad (3-31)$$

Donde  $x$  e  $y$  varían para que el centro (origen) del kernel visite cada píxel en  $f$ .

## Herramienta Central

La ecuación (3-31) es una herramienta central en el filtrado lineal. Para un valor fijo de  $(x, y)$ , implementa la suma de productos como en (3-30), pero para un kernel de tamaño impar arbitrario.



# Definición de Correlación Espacial

La **correlación espacial** es el proceso ilustrado gráficamente en la Fig. 3.28 y descrito matemáticamente por la Ec. (3-31).

- Consiste en mover el centro de un kernel sobre una imagen.
- En cada ubicación, se calcula la suma de productos entre los coeficientes del kernel y los píxeles correspondientes de la imagen.

La correlación de un kernel  $w$  con una imagen  $f(x, y)$ , denotada  $(w \star f)(x, y)$ , es:

$$(w \star f)(x, y) = \sum_{s=-a}^a \sum_{t=-b}^b w(s, t) f(x + s, y + t) \quad (3-34)$$

Para el caso 1D, la Ec. (3-31) se convierte en:

$$g(x) = \sum_{s=-a}^a w(s) f(x + s) \quad (3-32)$$

# Definición de Convolución Espacial

La mecánica de la **convolución espacial** es la misma que la correlación, con una diferencia clave:

- El kernel de correlación se **rota 180°** antes de realizar la operación de deslizamiento y suma de productos.

La convolución de un kernel  $w$  de tamaño  $m \times n$  con una imagen  $f(x, y)$ , denotada  $(w * f)(x, y)$ , se define como:

$$(w * f)(x, y) = \sum_{s=-a}^a \sum_{t=-b}^b w(s, t) f(x - s, y - t) \quad (3-35)$$

## Interpretación de los Signos

Los signos negativos en los argumentos de  $f(x - s, y - t)$  alinean las coordenadas de  $f$  y  $w$  cuando una de las funciones se rota 180°. Esta ecuación implementa el proceso que se conoce como **filtrado espacial lineal**.

**Filtrado espacial lineal y convolución espacial son sinónimos.**

# Manejo de Bordes: Padding

Cuando el kernel se superpone con los bordes de la imagen, algunos de sus coeficientes caen fuera del área de la imagen.

- La suma de productos queda indefinida en estas áreas.
- **Solución: Padding (Relleno).** Consiste en añadir píxeles alrededor de la imagen.
- **Zero-padding:** El método más común es rellenar con ceros.
- Si el kernel es de tamaño  $1 \times m$  (en 1D), se necesitan  $(m - 1)/2$  ceros a cada lado de la función  $f$ .
- Para un kernel 2D de  $m \times n$ , se rellena con un mínimo de  $(m - 1)/2$  filas de ceros arriba/abajo y  $(n - 1)/2$  columnas de ceros a izquierda/derecha.
- El padding asegura que el centro del kernel pueda visitar cada píxel de la imagen original.

## Otras opciones de padding

Existen otras estrategias de padding además del relleno con ceros (e.g., replicar bordes, padding simétrico), que se discuten en detalle en otras partes del material original.

# Correlación/Convolución con un Impulso Discreto

Un **impulso unitario discreto** es una función que es 1 en una ubicación y 0 en todas las demás. Para una imagen 2D, un impulso de amplitud  $A$  en  $(x_0, y_0)$  es:

$$\delta(x - x_0, y - y_0) = \begin{cases} A & \text{si } x = x_0, y = y_0 \\ 0 & \text{en otro caso} \end{cases} \quad (3-33)$$

(Para un impulso unitario,  $A = 1$ ).

## Correlación con un Impulso

Correlacionar un kernel  $w$  con un impulso unitario discreto produce una copia de  $w$  **rotada 180°** en la ubicación del impulso.

## Convolución con un Impulso

Convolucionar un kernel (o cualquier función)  $w$  con un impulso unitario discreto produce una **copia exacta** de  $w$  en la ubicación del impulso. Propiedad fundamental en sistemas lineales.

*Nota: Figuras 3.29 y 3.30 del texto original ilustran estos procesos detalladamente para casos 1D y 2D.*

# Ilustración Conceptual (Fig. 3.29 y 3.30)

## Idea Principal de Fig. 3.29 (1D) y Fig. 3.30 (2D)

Estas figuras muestran secuencias paso a paso de:

- Una función/imagen  $f$  (que es un impulso unitario).
- Un kernel  $w$  (no necesariamente simétrico).
- El proceso de padding de  $f$ .
- **Correlación:**
  - Deslizamiento del kernel  $w$  sobre  $f$  (paddeada).
  - Cálculo de la suma de productos en cada desplazamiento.
  - Resultado: versión del kernel  $w$  **rotada 180°**, centrada en la posición original del impulso.
- **Convolución:**
  - El kernel  $w$  se rota 180° *antes* del proceso de deslizamiento.
  - Deslizamiento del kernel  $w_{rotado}$  sobre  $f$  (paddeada).
  - Cálculo de la suma de productos.
  - Resultado: copia **exacta** del kernel  $w$  original, centrada en la posición del impulso.

# Tamaño del Resultado: "Full" vs "Same"

La cantidad de padding afecta el tamaño de la imagen resultante  $g(x, y)$ .

- **Padding para "Same.output":** Si se paddea la imagen  $f$  tal que el centro del kernel visita cada píxel original de  $f$  y la imagen resultante  $g$  tiene el *mismo tamaño* que  $f$ . Es el caso más común. Se necesitan  $(m-1)/2$  y  $(n-1)/2$  elementos de padding.
- **Padding para "Full.output":** Si se desea que *cada elemento* del kernel  $w$  ( $m \times n$ ) visite cada píxel de la imagen  $f$  ( $M \times N$ ).
  - Requiere más padding:  $(m-1)$  filas y  $(n-1)$  columnas.
  - El tamaño del arreglo resultante ( $S_v \times S_h$ ) es:

$$S_v = M + m - 1 \quad (3-36)$$

$$S_h = N + n - 1 \quad (3-37)$$

*Nota: En Ecs. (3-36) y (3-37) del texto,  $M, N$  son dims. de imagen y  $m, n$  del kernel.*

# Consideraciones Algorítmicas

- Muchos algoritmos de filtrado espacial están basados en la correlación (Ec. 3-34).
- Para usar un algoritmo de **correlación** para realizar **convolución**: se introduce el kernel  $w$  rotado  $180^\circ$ .
- Para usar un algoritmo de **convolución** (Ec. 3-35) para realizar **correlación**: se introduce el kernel  $w$  rotado  $180^\circ$  (menos común).
- Es decir, cualquiera de las Ecs. (3-34) o (3-35) puede realizar la función de la otra rotando el kernel.
- **Importante:** El orden de las funciones en un algoritmo de correlación sí importa, porque la correlación no es conmutativa ni asociativa (ver Tabla 3.5).

# Propiedades Fundamentales (Tabla 3.5)

**Cuadro:** Propiedades fundamentales de la convolución y correlación.

Propiedad	Convolución (*)	Correlación (★)
Conmutativa	$f * g = g * f$	—
Asociativa	$f * (g * h) = (f * g) * h$	—
Distributiva	$f * (g + h) = (f * g) + (f * h)$	$f ★ (g + h) = (f ★ g) + (f ★ h)$

(Un —indica que la propiedad no se

cumple.)

## Relevancia de las Propiedades de la Convolución

La conmutatividad y asociatividad de la convolución son cruciales:

- Permiten el **filtrado secuencial** eficiente.
- Son la base de la **teoría de sistemas lineales e invariantes al desplazamiento (LSI)**.
- Permiten la **separabilidad de kernels** (kernel 2D → dos convoluciones 1D).



# Ejemplos de Kernels de Suavizado (Fig. 3.31)

Los kernels de suavizado (filtros paso-bajas) se usan para reducir ruido y difuminar detalles.

a) Box Kernel (Promediador):

	1	1	1
$\times \frac{1}{9}$	1	1	1
	1	1	1

Reemplaza cada píxel por el promedio de su vecindad  $3 \times 3$ . Todos los coeficientes son iguales.

(b) Gaussian Kernel (Ponderado):

	0,3679	0,6065	0,3679
$\times \frac{1}{4,8576}$	0,5408	1,0000	0,6065
	0,3679	0,6065	0,3679

Los coeficientes siguen una Gaussiana. Dan más peso a píxeles centrales. Factor de norm. es suma de coefs.

## Nota sobre Simetría

Ambos kernels son simétricos respecto a su centro. Por lo tanto, para estos kernels, la correlación y la convolución producirían el mismo resultado. No se requiere rotación previa para la convolución.

# Terminología en la Literatura

Es común encontrar una terminología algo imprecisa:

- **"Filtro de convolución", "máscara de convolución", "kernel de convolución"** a menudo se usan para denotar un kernel de filtro espacial, sin implicar necesariamente que el kernel se use estrictamente para la operación matemática de convolución (podría usarse en una correlación).
- **Convolucionar un kernel con una imagen** se usa frecuentemente de manera genérica para referirse al proceso de deslizamiento y suma de productos, sin diferenciar estrictamente entre correlación y convolución.

En este contexto (y en gran parte de la teoría de procesamiento de imágenes):

Cuando se habla de **filtrado espacial lineal**, se refiere a la **convolución** de un kernel con una imagen.

# Filtrado Secuencial

Una imagen  $f$  puede ser filtrada secuencialmente, en  $Q$  etapas, usando un kernel diferente  $(w_1, w_2, \dots, w_Q)$  en cada etapa:  $f \xrightarrow{w_1} g_1 \xrightarrow{w_2} g_2 \dots \xrightarrow{w_Q} g_Q$ . Debido a la propiedad **asociativa** de la convolución, esta operación multi-etapa es equivalente a una única operación de filtrado  $w * f$ , donde el kernel efectivo  $w$  es la convolución de todos los kernels individuales:

$$w = w_1 * w_2 * w_3 * \dots * w_Q \quad (3-38)$$

## Importancia

Esto permite, por ejemplo, diseñar filtros complejos a partir de filtros más simples, o analizar el efecto combinado de varias operaciones de filtrado. No se podría escribir una ecuación similar para la correlación debido a su falta de asociatividad.

# Tamaño del Kernel en Filtrado Secuencial

Si todos los kernels individuales  $w_i$  en un filtrado secuencial de  $Q$  etapas son de tamaño  $m \times n$ , y se asume convolución "full", en cada paso intermedio (es decir, cada valor de un kernel visita cada valor del arreglo resultante del paso anterior), el kernel combinado  $w$  (de la Ec. 3-38) será de tamaño  $W_v \times W_h$ :

$$W_v = Q \times (m - 1) + m \quad (3-39)$$

$$W_h = Q \times (n - 1) + n \quad (3-40)$$

- Estas ecuaciones se derivan de aplicaciones sucesivas de las Ecs. (3-36) y (3-37) para el tamaño de una convolución "full".
- Ejemplo: Si  $Q = 2$  kernels de  $3 \times 3$  ( $m = 3, n = 3$ ):
  - $W_v = 2 \times (3 - 1) + 3 = 2 \times 2 + 3 = 7$
  - $W_h = 2 \times (3 - 1) + 3 = 2 \times 2 + 3 = 7$
  - El kernel combinado  $w = w_1 * w_2$  sería de  $7 \times 7$ .

# Puntos Clave del Filtrado Espacial Lineal

- Modifica píxeles mediante una **suma de productos** con un **kernel**.
- La **correlación**  $(w \star f)(x, y) = \sum \sum w(s, t) f(x + s, y + t)$  es la aplicación directa de esta suma.
- La **convolución**  $(w * f)(x, y) = \sum \sum w(s, t) f(x - s, y - t)$  implica rotar el kernel 180° (o ajustar índices) y es la base del filtrado lineal.
- Operar con un **impulso unitario** revela la diferencia:
  - Correlación  $\rightarrow$  kernel rotado.
  - Convolución  $\rightarrow$  kernel original.
- El **padding** es crucial para manejar los bordes de la imagen y controlar el tamaño de la salida.
- La convolución es **conmutativa y asociativa**, propiedades vitales para la teoría de sistemas y el filtrado secuencial eficiente.
- El tamaño del kernel resultante de un filtrado secuencial puede determinarse a partir de los tamaños de los kernels individuales.

## Importancia del Filtrado Espacial

El filtrado espacial lineal, fundamentado en la operación de convolución, es una de las herramientas más versátiles y fundamentales en el procesamiento digital de imágenes. Comprender su mecánica, la diferencia entre correlación y convolución, y las propiedades de estas operaciones es esencial para:

- Diseñar y aplicar filtros para una amplia gama de tareas (suavizado, realce de bordes, detección de características, etc.).
- Analizar el comportamiento de sistemas de procesamiento de imágenes.
- Desarrollar algoritmos eficientes.

## Próximos Pasos

Las secciones y capítulos subsecuentes del material original explorarán tipos específicos de filtros espaciales (lineales y no lineales) y sus aplicaciones, así como el filtrado en el dominio de la frecuencia.

**¿Preguntas?** ¡Gracias por su atención!